上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

SJTU



互联网产品开发与运维

任锐

2026/10/13

饮 水 思 源 • 爱 国 荣 校

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY



互联网产品开发与运维

资源：计算 / 存储 / 网络

模块 5 · 重新认识软件（3/4）

饮 水 思 源 • 爱 国 荣 校

SJTU

本讲位置：从「资源占用」到「资源上限」

上一讲 · L-06

运行中的软件表现为进程，占用线程、内存与文件描述符（fd）

单机 Tomcat 的四个上限：线程池耗尽是表象，热点行锁是根因

遗留问题：四个上限仅涉及 CPU、线程与连接，未涉及磁盘和网络

本讲问题

软件消耗哪些资源？各资源的上限由什么决定，饱和有何征兆，需求如何换算为容量？

引例

开放日 9:03：CPU 30%、内存余量约一半、带宽 5%，提交 p99 却达 2 s。三项指标均未告警，为何仍然缓慢？

在课程实践中以资源账解答

本讲结构

1 资源的三问

2 计算：CPU 与内存

3 存储

4 网络 · 资源测量实验

5 课程实践：选课平台开放日的资源账

本模块 重新认识软件（L-05 ~ L-08）：制品（L-05）· 进程（L-06）· 资源（本讲）· 指标（L-08） | 思考题 2 于 10 月 15 日（周四）23:59 截止

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY



互联网产品开发与运维

一、资源的三问

第七讲 · 资源：计算 / 存储 / 网络

饮 水 思 源 • 爱 国 荣 校

SJTU

资源的三问

对每种资源提出三个问题

上限由什么决定?

核数、内存大小、IOPS、fsync 延迟、带宽、RTT

有的由购买的规格决定，有的受物理条件约束

如何判断饱和?

利用率衡量资源被占用的程度，饱和度衡量是否有请求在等待

运行队列、swap、磁盘队列、重传：不同资源的等待表现形式不同

如何换算?

需求 = 单请求占用 × QPS

容量 = 上限 × 目标利用率

比较需求与容量即可得出结论

承接 L-06 的「四个上限」

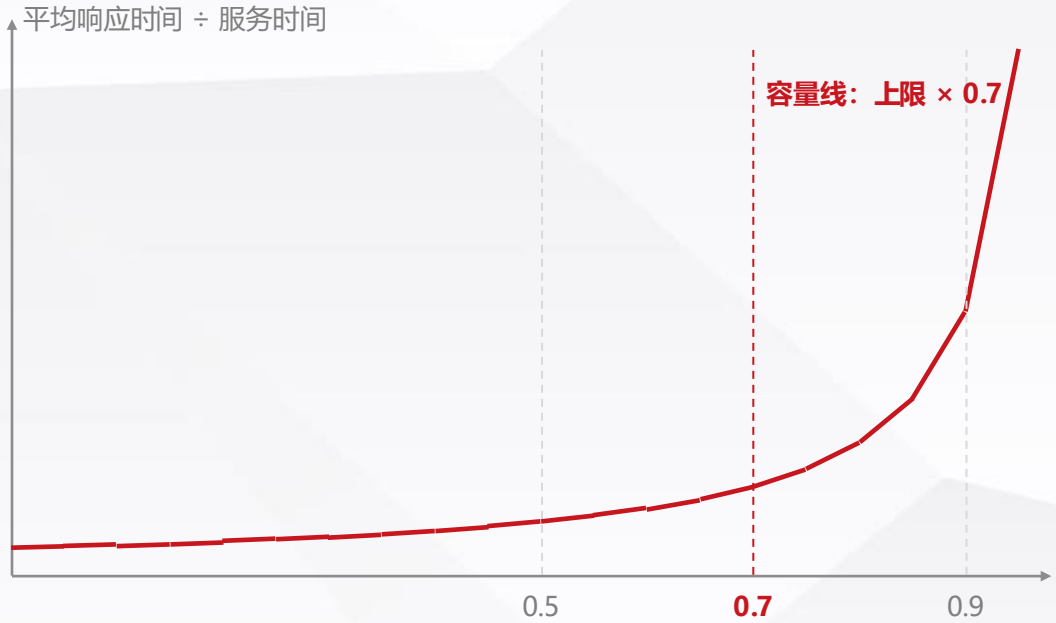
L-06 的上限表仅涵盖 CPU、连接池、线程池与连接；本讲补充内存工作集、磁盘 IOPS 与 fsync、网络带宽与 RTT，形成整个平台的资源账

要点 利用率未告警不代表资源未饱和；每种资源的等待须单独观测

来源：B. Gregg, Systems Performance, 2nd ed. (2020), Ch. 2（其中的 USE 方法在 L-08 展开）

资源的三问 · 排队

为什么利用率不宜接近 100%



横轴为利用率 ρ；M/M/1 模型：平均响应时间 = 服务时间 ÷ (1 − ρ)，ρ 超过 0.7 后急剧上升

利用率 ρ	平均响应时间	对照思考题 1
0.5	2 倍服务时间	—
0.6	2.5 倍	800 QPS，p95 150 ms
0.8	5 倍	—
0.9	10 倍	1200 QPS，p95 1.8 s
0.95	20 倍	1500 QPS，错误率 9%

容量规划按「上限 × 0.7」计算：预留的 30% 并非浪费，而是用于吸收排队；突发越大，所需余量越多

要点 上限由资源本身决定，容量是预留余量之后的上限

来源：Gregg, Ch. 2.6 排队论；思考题 1 教师要点（单机压测表）

延迟数量级：本讲的参照表

操作	量级	对应章节
内存访问	100 ns	计算
SSD 随机读	几十 ~ 一百 µs	存储
云盘（网络挂载）一次 IO	0.5 ~ 2 ms	存储
机械盘寻道	5 ~ 10 ms	存储
fsync：NVMe / 云盘 / 机械盘	0.1 ms / 1 ~ 3 ms / 10 ms	存储
机房内 RTT	0.1 ~ 0.5 ms（思考题 2 取 0.2 ms）	网络
同城 / 跨省 / 跨国 RTT	1 ~ 3 ms / 20 ~ 40 ms / 100 ~ 200 ms	网络
1 Gbps 链路传输 1 MB	≈ 10 ms	网络

相邻层级相差 10 ~ 100 倍。计算的上限主要取决于核数；存储与网络的上限还受单次操作延迟的制约，请求在等待设备或链路时形成排队

要点 先掌握数量级，再讨论优化；相差一个数量级的差异无需测量即可判断

来源：J. Dean, Numbers Everyone Should Know；C. Scott, Latency Numbers Every Programmer Should Know（量级示意）

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY



互联网产品开发与运维

二、计算：CPU 与内存

第七讲 · 资源：计算 / 存储 / 网络

饮 水 思 源 • 爱 国 荣 校

SJTU

CPU：上限的来源

上限

每个核每秒最多提供 1000 ms CPU 时间

QPS 上限 = 核数 ÷ 单请求 CPU 时间（s）

L-06：4 核、3 ms → 1333

云主机的 vCPU

1 个 vCPU 通常对应一个超线程，而非一个物理核

同名规格在不同代次间主频不同

steal（%st）：vCPU 等待宿主机调度的时间占比

饱和征兆

运行队列（vmstat 的 r）持续超过核数

%st 持续大于零

cgroup 节流计数增长（L-06）

上下文切换次数骤增

换算

所需核数 = QPS × 单请求 CPU 时间（ms）÷ 1000 ÷ 0.7

0.7 为目标利用率（容量线）

问题	原因	对策
CPU 利用率 50% 但响应慢	单核热点、steal 或 cgroup 节流	分核查看，并检查 %st 与节流计数
增加核数后性能未提升	瓶颈不在 CPU，或受串行部分限制（Amdahl 定律，L-03）	先确认 CPU 饱和，再扩容

要点 CPU 的上限是购买的核数；判断饱和应看是否有线程在等待 CPU，而非利用率百分比

来源：Gregg, Ch. 6；Linux top(1)（%st 说明）

内存：上限的来源

上限：工作集能否驻留内存

而非已使用的内存量

能驻留 → 内存访问（约 100 ns）

不能驻留 → 访问磁盘，延迟高 1000 ~ 10000 倍

三类内存使用者

进程的 RSS（L-06）

页缓存：缓存文件与日志数据

数据库的 buffer pool：由数据库自行管理，按热数据规模配置

饱和征兆

available 接近零

swap in / out（vmstat 的 si / so）持续非零

major page fault 增多；OOM Kill（退出码 137）

运行时层面：GC 频率与停顿时间上升

换算

实例内存 = 堆 + 堆外 + 每连接缓冲 × 连接数；主机内存 = Σ 实例内存 + 页缓存 / buffer pool 预留

数据库主机：buffer pool ≥ 热数据 × 1.2，并以命中率校验

要点 内存饱和的首个征兆通常不是 OOM，而是延迟普遍上升，其原因是 swap 与缓存未命中

来源：Gregg, Ch. 7；MySQL 8.4 Reference, InnoDB Buffer Pool

计算资源的常见误判

问题	原因	对策
4 核主机上某进程 %CPU 为 100%，误判为 CPU 已满	单进程最高可达 400%，100% 仅相当于一个核	分核查看（mpstat -P ALL）
CPU 平均 40%，但 p99 偏高	个别核或个别时段饱和，或存在 steal、节流	分核、分时段查看，并检查 %st 与节流计数
内存 used 达 90% 即扩容	其中大部分是可回收的页缓存	以 available 与 swap 为准，而非 used
增加 CPU 与内存均无效	瓶颈在磁盘或网络（见后两节）	先定位已饱和的资源

要点 CPU 与内存都存在「利用率未满但已饱和」的情形，这是解释引例的第一条线索

来源：Gregg, Ch. 6、7

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY



互联网产品开发与运维

三、存储

第七讲 · 资源：计算 / 存储 / 网络

饮 水 思 源 • 爱 国 荣 校

SJTU

存储：三项指标与两种访问模式

三项指标

IOPS：每秒完成的 IO 次数

吞吐量：每秒传输的数据量（MB/s）

延迟：单次 IO 的完成时间

两种访问模式

随机或同步小 IO（数据库页读写、日志追加后 fsync）受 IOPS 与延迟限制

顺序大 IO（备份、全表扫描、视频）受吞吐量限制

云盘性能按规格购买

IOPS 与吞吐量按规格和容量计费，部分类型提供突发额度

本地盘性能高，但数据随实例释放而丢失

机械盘成本低，但随机 IOPS 仅为百次量级

换算

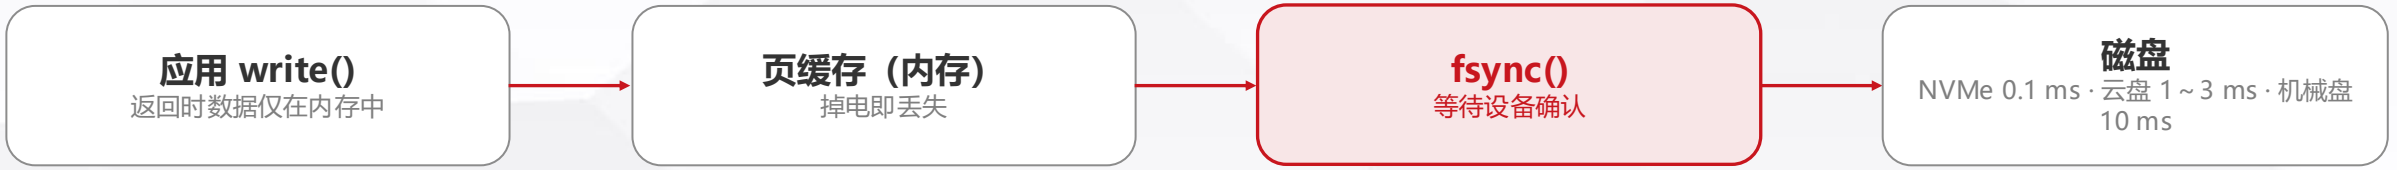
IOPS 需求 = 写 TPS × 每事务 IO 数 + 读 QPS × 未命中率

吞吐量需求 = IOPS × 单次 IO 大小

要点 选购磁盘前先确定访问模式是随机还是顺序，再据此以 IOPS 或 MB/s 为主要指标

来源：Gregg, Ch. 9 Disks；华为云云硬盘性能说明（规格以当前文档为准）

fsync 与持久性



写入页缓存 ≠ 持久化：write() 返回时数据仍在内存中；fsync() 在设备确认写入后才返回

数据库每次提交至少执行一次 fsync

redo log 一次；启用 binlog 时再加一次

写 TPS 上限 ≈ 1 ÷ fsync 延迟 ÷ 每事务 fsync 数（组提交可合并 fsync）

估算

云盘 fsync 延迟 2 ms → 单盘串行 fsync 约 500 次/秒

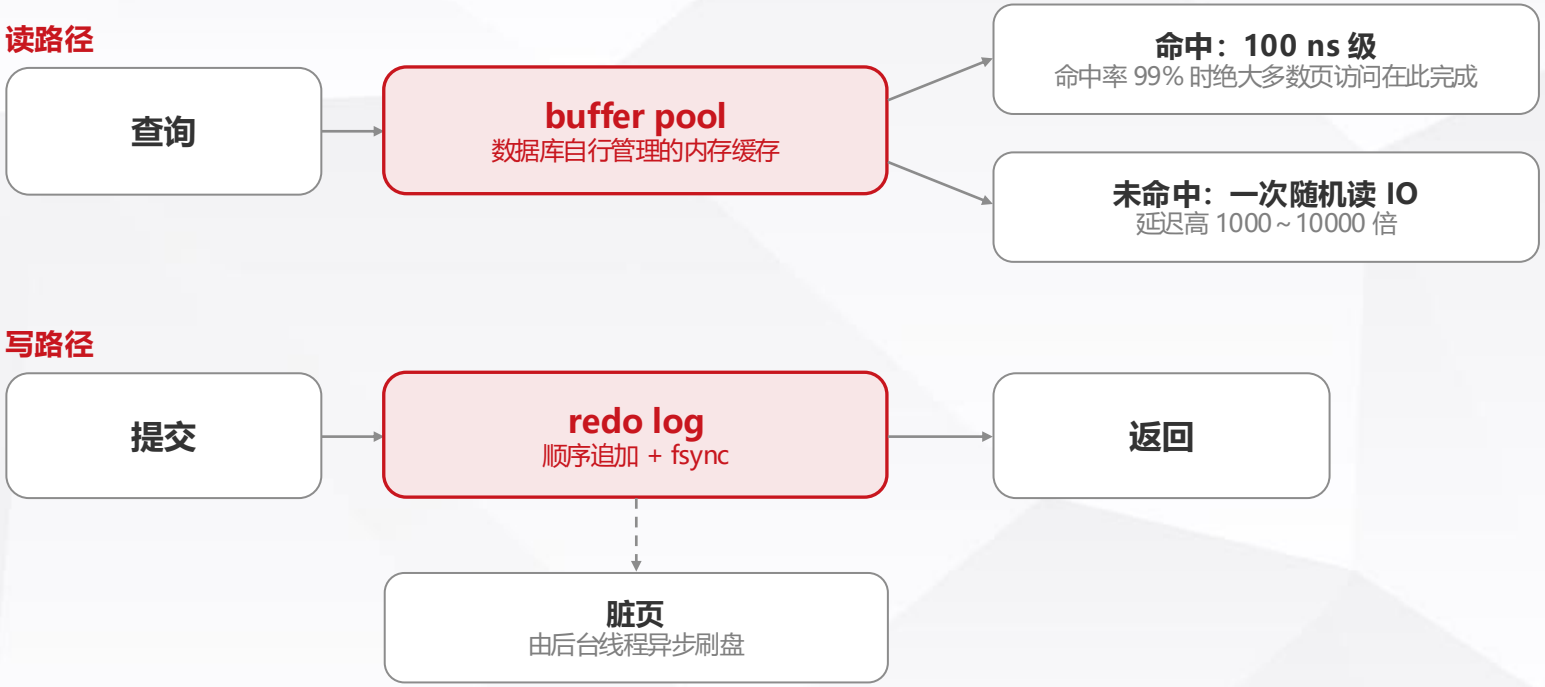
每次提交 2 次 fsync → 250 TPS；本地 NVMe 0.1 ms → 5000 TPS

问题	原因	对策
写吞吐量无法提升，CPU 利用率低	每次提交都在等待 fsync	更换低延迟磁盘；组提交或批量提交；减少每个事务的 fsync 次数
改为每秒刷盘一次，吞吐量提升数倍	代价：宕机时最多丢失约 1 秒内已提交的事务	取决于业务能否容忍丢失；选课记录不能容忍

要点 持久性以延迟为代价；写路径的上限由 fsync 的延迟与次数决定

来源：Linux fsync(2)；MySQL 8.4 Reference, innodb_flush_log_at_trx_commit、sync_binlog

数据库在存储层级中的位置



关联 L-04：读写分离与分库分表将上述两类上限分摊到更多机器

读上限：命中率

命中率 99% 与 90% 相比，磁盘读次数相差 10 倍

因此 buffer pool 应按热数据规模配置

写上限：fsync 与 IOPS

CPU 通常不是数据库的首要瓶颈

锁、事务与索引的影响留待机动课时讨论

要点 数据库是存储资源的使用者，其上限在很大程度上由存储决定

来源：MySQL 8.4 Reference, InnoDB Architecture（buffer pool、redo log）

存储的饱和征兆与换算

观测项

iostat：await（单次 IO 平均耗时）上升、aqu-sz（旧版 avgqu-sz）持续 > 1、%util 接近 100（SSD 仅作参考）

vmstat 的 b 列：阻塞等待 IO 的进程数

数据库侧：脏页积压、buffer pool 命中率下降

换算

fsync/s 需求 = 写 TPS × 每事务 fsync 次数，与 1 ÷ fsync 延迟比较

IOPS 需求 = 写 TPS × 每事务 IO 数 + 读 QPS × 未命中率，与磁盘规格比较

await 率先上升 → **队列增长**（aqu-sz > 1） → **上层线程阻塞**（线程池排队（L-06）） → **锁持有时间延长**（事务持锁期间等待磁盘） → **吞吐量达到上限**（CPU 仍较空闲）

征兆的传导顺序：从磁盘队列逐级传导至应用线程池，而常见仪表盘通常只展示最后一环

要点 磁盘是仪表盘上最常被遗漏的资源，也是解释引例的另一条线索

来源：Linux iostat(1)、vmstat(8)

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY



互联网产品开发与运维

四、网络

第七讲 · 资源：计算 / 存储 / 网络

饮 水 思 源 • 爱 国 荣 校

SJTU

带宽与延迟

带宽决定传输速率，延迟决定往返时间

增加带宽不会缩短 RTT；RTT 主要由传播距离决定

一次请求包含多次往返

TCP 握手 1 RTT、TLS 握手 1 ~ 2 RTT、请求 1 RTT；机房内 RTT 约 0.2 ms，跨省为数十 ms

回顾思考题 2 第一幕：一次 curl 请求 20 ms 的耗时分解



服务端处理仅占 15%，其余 17 ms 与服务端无关；减少一次往返的收益大于服务端提速 1 ms

长连接复用可省去握手

L-03 的 HTTP/2、L-06 的 keep-alive：复用连接后，机房内单次调用的网络开销约 0.5 ms

换算

网络耗时 ≈ 往返次数 × RTT + 数据量 ÷ 带宽

要点 延迟按往返次数核算，带宽按传输字节数核算

来源：思考题 2 教师要点（第一幕）；Gregg, Ch. 10 Network

带宽核算

出口带宽 = QPS × 响应大小 × 8

1 Gbps ≈ 125 MB/s，实际可用约 100 MB/s

公网带宽以 Mbps 为单位购买（EIP，按带宽或按流量计费）

内网带宽由实例规格决定，通常为 Gbps 级

估算

2400 QPS × 8 KB = 19.2 MB/s ≈ 154 Mbps

100 Mbps 的 EIP 已无法满足

首页 200 KB 若不经 CDN：2400 × 200 KB = 480 MB/s

约 3.8 Gbps，远超常规 EIP 带宽规格

问题	原因	对策
带宽达到上限：不报错，但延迟上升	限速导致排队：RTT 上升、重传增加	常规指标同样不告警：检查 txkB/s 与重传
带宽需求超出容量	响应体过大、静态资源未经 CDN、未启用压缩	CDN（L-04 插曲）、gzip、精简响应；按峰值采购带宽

要点 公网带宽是资源账中成本最高、最易估错的一项；应优先将静态资源分流至 CDN

来源：华为云弹性公网 IP 计费说明（以当前文档为准）；L-04 讲义（插曲 · 前端）

连接、端口与 NAT：云上网络资源按规格计费

端口

单个源 IP 对同一目标地址和端口的并发连接数受临时端口范围限制，约 2.8 万 ~ 6 万条

处于 TIME_WAIT 的连接仍占用端口（L-06）

NAT 网关

SNAT 并发连接数按规格售卖（万级至百万级，以当前规格表为准）

未绑定 EIP 的实例访问公网（短信、支付、大模型 API 等）均经过 NAT 网关

连接跟踪（conntrack）

安全组、防火墙与 NAT 均需记录每条连接的状态

表满后新连接被丢弃，应用侧无明确报错，是最难排查的饱和之一

PPS

云主机按规格限制每秒包数（PPS），而不仅限制带宽

小包占比高的服务会先达到 PPS 上限

回顾 L-01 第一周绘制的 VPC、NAT、EIP 与安全组，每个组件都是有上限且需付费的资源

来源：华为云 NAT 网关 / 安全组文档（规格以当前文档为准）；Linux nf_conntrack

网络的饱和征兆与换算

观测项

重传率（ss -tin 的 retrans、netstat -s）与 RTT 上升
listen overflow：accept 队列溢出（L-06）
conntrack full（内核日志）；带宽与 PPS（sar -n DEV）

换算

所需带宽 = QPS × 响应大小 × 8 ÷ 0.7
并发连接数 = 在线用户数 × 每用户连接数（L-06）
出公网并发连接数 = 外部接口调用 QPS × 平均连接占用时长（Little's Law）

问题	原因	对策
内网调用偶发超时	conntrack 表满或 PPS 达到上限	检查内核日志与 rxpck/s；调整表容量或升级规格
外部接口连接失败	NAT 并发连接数达到上限	检查 NAT 监控；升级规格或复用长连接

要点 网络饱和通常不产生显式错误，而是表现为延迟上升与丢包，因此须主动监测重传与队列

来源：Linux ss(8)、sar(1)

实验预告

实验设计：逐项使资源饱和，识别其征兆

资源	施加负载的方式	观测工具	判据
CPU	纯计算接口 + 压测	mpstat -P ALL、perf + 火焰图	某核 %usr 接近 100；运行队列 > 核数
内存 / GC	大量分配短生命周期对象，或使工作集超出内存	pidstat -r、堆分析、GC 日志	RSS 上升、GC 频率上升、p99 随 GC 波动
磁盘	大块写入 + fsync	iostat -x、biolatency	await 上升、%util 接近 100、吞吐量接近规格
网络	大响应体 + 高并发	sar -n DEV、ss -tin	txkB/s 接近规格、重传上升

实验中每次只使一种资源饱和，以便识别其征兆；生产环境中须同时观测四类资源

本年度实验已重新设计，具体接口与步骤以实验指导书为准

要点 本讲的三个问题对应实验报告的三个部分：上限、征兆与换算

来源：Gregg, Systems Performance, Ch. 2（方法论）

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY



互联网产品开发与运维

五、课程实践：选课平台开放日的资源账

第七讲 · 资源：计算 / 存储 / 网络

SJTU

课程实践

参数设定：沿用思考题 1 后期阶段与 L-06 的设定

平台与峰值需求

Nginx（TLS 终结，EIP 200 Mbps）+ 4 × Tomcat（4 核 8 GB）

1 × MySQL（4 核 8 GB，通用型云盘：3000 IOPS，fsync ≈ 2 ms）

读 2400 QPS（4 台各 600）；写 300 TPS，开放后前 10 秒写需求达 600 TPS

在线 2000 人，每人 4 条连接；首页 200 KB 经 CDN 分发

单请求资源消耗

查询：Tomcat CPU 3 ms；本地缓存命中率 70%，其余请求访问 MySQL（CPU 0.5 ms，buffer pool 命中率 99%）；响应为 8 KB 未压缩 JSON

提交：Tomcat CPU 5 ms；MySQL CPU 2 ms；2 次 fsync（redo + binlog）

以上参数为教学设定值，与 L-06 课程实践及思考题 1 压测表保持一致

引例 9:03：CPU 利用率 30%，内存余量约一半，带宽利用率 5%，提交 p99 为 2 s；请据此编制资源账

资源账

资源	峰值需求	容量	利用率	饱和观测项
Tomcat CPU	2400 × 3 ms + 300 × 5 ms = 8.7 核	16 核	54%	运行队列、%st
MySQL CPU	720 × 0.5 ms + 300 × 2 ms ≈ 1 核	4 核	25%	同上
Tomcat 内存	每台 RSS ≈ 4.5 GB	8 GB	56%	available、swap
MySQL 内存	热数据 2 GB；buffer pool 6 GB	8 GB	命中 99%	命中率、swap
MySQL 磁盘	300 × 2 = 600 fsync/s（600 TPS 时 1200）	fsync 2 ms → ≈ 500/s	120%	await、aqu-sz、%util
出口带宽	2400 × 8 KB × 8 = 154 Mbps	200 Mbps	77%	txkB/s、重传
连接（Nginx）	2000 × 4 = 8000	10240 连接	78%	ss -s、listen overflow

引例解答：三项指标均未告警，饱和发生在磁盘。每次提交需等待两次 fsync，云盘单次 fsync 约 2 ms，处理能力约 500 次/秒，而需求为 600 次/秒；await 由 2 ms 升至 20 ms，提交变慢，热点行的锁持有时间随之延长，吞吐量被限制在 300 TPS，线程池占满，提交 p99 达 2 s

要点 思考题 1 的行锁串行（s ≈ 0.25）与磁盘 fsync 相关：锁持有时间中包含等待 fsync 的时间

课堂讨论

1 三项指标均未告警，为何响应缓慢?

依据资源三问：仪表盘遗漏了哪些资源？各自的饱和征兆是什么？

排查时应首先查看哪项指标？

2 写路径的上限由什么决定?

将 redo log 与 binlog 改为每秒刷盘一次，收益与代价各是什么？选课记录是否适用?

还有哪些方法能使 fsync 需求不超过容量？

3 带宽

响应为 8 KB 时需 154 Mbps，接近 200 Mbps 上限；启用 gzip（JSON 压缩比约 5:1）后需要多少?

首页 200 KB 为何必须经 CDN 分发？带宽超限时是否会报错?

4 设计一个最小实验

分别使 CPU、内存、磁盘、网络饱和：各需施加何种负载?

各自观测哪些指标？判据是什么?

安排 每题小组讨论 2 分钟、汇报 1 分钟，其余时间讲评

讨论要点

1 定位饱和资源

仪表盘缺少磁盘与重传指标：先查看数据库主机 iostat 的 await 与 %util，再查看 Nginx 主机的重传（ss -tin）与 listen overflow

原则：常规指标未告警时，逐项检查各资源的等待

2 写路径

上限 = 1 ÷ fsync 延迟 ÷ 每事务 fsync 数；每秒刷盘可提升吞吐量数倍，但宕机最多丢失约 1 s 的提交，选课记录不可丢失

可行措施：高性能云盘或本地 NVMe（fsync 0.2 ms，约 2500 TPS）、组提交、减少 fsync 次数

结构性措施：将余量扣减移至 Redis，使热点写路径移出数据库（思考题 1 第五幕）

3 带宽

gzip 压缩后约 1.6 KB → 31 Mbps，余量由 23% 提高到 85%

首页 200 KB × 2400 = 480 MB/s（约 3.8 Gbps），远超常规 EIP 规格，静态资源必须经 CDN 分发

带宽超限不报错，而是限速排队：RTT 与重传上升，常规指标同样不告警

4 最小实验

CPU：纯计算接口 → 单核 100%、运行队列、火焰图

内存：大量短生命周期分配 → RSS、GC 频率、p99 波动

磁盘：大块写入 + fsync → await、%util

网络：大响应体 + 高并发 → txkB/s、重传；每次只测一种资源

结论 三项常规指标均未告警，饱和发生在未纳入监控的磁盘；将各资源的等待指标纳入仪表盘，是下一讲「指标」的内容

本讲小结

- **每种资源的三个问题**
  - 上限由什么决定、如何判断饱和、如何换算容量
- **计算**
  - 上限取决于核数与工作集；依据运行队列、steal、swap 判断饱和，而非仅凭利用率
- **存储**
  - 上限：IOPS 与 fsync 延迟；持久性以延迟为代价；读写分别受命中率与 fsync 制约
- **网络**
  - 延迟按往返次数计，带宽按字节数计；云上网络组件均为有上限的付费资源；饱和通常不报错
- **容量 = 上限 × 0.7；利用率未告警不代表资源未饱和**

判断标准 该资源的上限由什么决定？如何判断其饱和？

课后思考与参考资料

课后思考

1. 为小组项目的部署编制一份资源账（格式参照本讲资源账表），逐行列出需求、容量、利用率与饱和观测项；哪一项最先达到上限？

2. 查阅小组所用云盘的规格：IOPS、吞吐量与 fsync 延迟分别是多少（fsync 延迟通常需自行测量）？据此计算其可支持的写 TPS 上限。

3. 基于思考题 2 第一幕的 curl 耗时分解，计算选课平台迁移至异地机房（RTT 30 ms）后一次首页请求的网络耗时；其中哪一项是主要因素？

参考资料

B. Gregg, Systems Performance: Enterprise and the Cloud, 2nd ed. (2020), Ch. 2、6、7、9、10

J. Dean, Numbers Everyone Should Know；C. Scott, Latency Numbers Every Programmer Should Know

MySQL 8.4 Reference Manual：InnoDB Buffer Pool；innodb_flush_log_at_trx_commit；sync_binlog

Linux man pages：fsync(2)、iostat(1)、sar(1)、ss(8)、vmstat(8)、mpstat(1)

华为云文档：云硬盘性能、弹性公网 IP 计费、NAT 网关规格（以当前版本为准）

思考题 1、2 题面与教师要点

感谢聆听

饮 水 思 源　爱 国 荣 校